



Ανάλυση Αποχωρήσεων Πελατών (Customer Churn) σε Τηλεπικοινωνιακό Πάροχο με χρήση Apache Spark

2η Ομαδική Εργασία

Ομάδα:	Γεωργιάνα Πετρίδου , Θεοδώρα Στάμογλου
ΑΜ:	ics23143, iis22144
Διδάσκουσα:	Δρ.Δημαρά Ασημίνα
Καταληκτική Ημερομηνία:	9/1/2026

Πίνακας Περιεχομένων

1. Εισαγωγή.....	3
2. Θέμα 1: Φόρτωση, Έλεγχος και Καθαρισμός Δεδομένων.....	4
3. 1. Φόρτωση και Επισκόπηση Δεδομένων.....	4
4. 2. Έλεγχος Ελλιπών Τιμών (Missing Values).....	4
5. 3. Στρατηγική Καθαρισμού (Cleaning Strategy).....	5
6. 4. Βασική Περιγραφική Ανάλυση.....	6
7. 5. Αρχικό Feature Engineering.....	7
8. Θέμα 2: Ανάλυση με Spark SQL & Επιβεβαίωση Επιχειρησιακών Μοτίβων.....	8
9. 1. Δημιουργία προσωρινού view(churn_view).....	8
10. 2. Βασικά ερωτήματα ανάλυσης churn.....	9
11. 3. Γεωγραφική ανάλυση (Top-X περιοχές).....	10
12. Θέμα 3 : Πρόβλεψη Μηνιαίας Χρέωσης με Decision Tree για δυναμική τιμολόγηση.....	11
13. 1. Προεπεξεργασία & Pipeline.....	11
14. 2. Εκπαίδευση και αξιολόγηση.....	11
15. Βιβλιογραφία.....	11

1. Εισαγωγή

Η αποχώρηση πελατών (customer churn) αποτελεί ένα από τα σημαντικότερα προβλήματα που αντιμετωπίζουν οι τηλεπικοινωνιακοί οργανισμοί σήμερα, καθώς επηρεάζει άμεσα τα έσοδα, τη βιωσιμότητα και τη στρατηγική ανάπτυξή τους. Κρίσιμα σημεία για την αντιμετώπιση αυτού του φαινομένου είναι η δυνατότητα κατανόησης των παραγόντων που οδηγούν τους πελάτες στην αποχώρηση, καθώς και η έγκαιρη πρόβλεψη της συμπεριφοράς τους, τα οποία στοχεύουν στον σχεδιασμό πολιτικών διατήρησης πελατών. Για τον λόγο αυτό, η εύρεση μοτίβων και πιθανών συμπερασμάτων είναι καθοριστική για την κατανόηση της κατάστασης, αλλά και την μελλοντική στρατηγική της εκάστοτε εταιρείας. Η παρακάτω εργασία αναλύει δεδομένα αποχωρήσεων πελατών τηλεπικοινωνιακού παρόχου, χρησιμοποιώντας το Apache Spark. Βασικά σημεία είναι η διαχείριση ελλιπών δεδομένων και η κατασκευή ενός μοντέλου μηχανικής μάθησης με Spark ML, σε σενάριο παλινδρόμησης βασισμένο σε χαρακτηριστικά πελατών και συμβολαίων, για πρόβλεψη μηνιαίων χρεώσεων.

Θέμα 1: Φόρτωση, Έλεγχος και Καθαρισμός Δεδομένων

1. Φόρτωση και Επισκόπηση Δεδομένων

Αρχικά, δημιουργήσαμε το SparkSession και φορτώσαμε το αρχείο “telecom_churn_10k.csv” κάνοντας χρήση του “inferSchema=True” για την αυτόματη αναγνώριση των τύπων δεδομένων.

```
spark = SparkSession.builder.appName("Telecom Churn Analysis").getOrCreate()
df = spark.read.csv("telecom_churn_10k.csv", header=True, inferSchema=True)

print("--- Φόρτωση & Έλεγχος Δεδομένων ---")
print("\nΠρώτες 10 γραμμές:")
df.show(10)

print("\nΣχήμα (Schema):")
df.printSchema()

total_records = df.count()
print(f"\nΣυνολικός αριθμός εγγαφών: {total_records}\n")
```

2. Έλεγχος Ελλιπών Τιμών (Missing Values)

Υπολογίσαμε το πλήθος των ελλιπών τιμών ('null' ή 'NaN') για κάθε στήλη, έτσι ώστε να δούμε ποιες τιμές λείπουν και από ποια στήλη.

--- Έλεγχος Ελλιπών Τιμών ---

Συγκεντρωτικός Πίνακας Ελλιπών Τιμών:

column_name	missing_count
AGE	300
TENURE_MONTHS	300
MONTHLY_CHARGES	300
TOTAL_CHARGES	300
CHURN	300

Σημείωση: Συνολικές εγγραφές: 10000 (10000 αναμενόμενο)

Εστιάζοντας στα πεδία ενδιαφέροντος:

CHURN: Οι ελλιπείς τιμές εδώ είναι κρίσιμες καθώς αποτελούν τη μεταβλητή-στόχο. Η ύπαρξη 'null' εμποδίζει την εκπαίδευση του μοντέλου.

TOTAL_CHARGES: Παρατηρήθηκε σημαντικός αριθμός ελλιπών τιμών. Συχνά αυτό οφείλεται σε νέους πελάτες (Tenure = 0) ή σε προβλήματα format κατά τη φόρτωση.

AGE / TENURE_MONTHS: Οι ελλιπείς τιμές σε δημογραφικά στοιχεία και διάρκεια συμβολαίου πρέπει να συμπληρωθούν για να μη χαθεί η πληροφορία των υπόλοιπων χαρακτηριστικών της εγγραφής.

3. Στρατηγική Καθαρισμού (Cleaning Strategy)

Για τη διαχείριση των ελλιπών δεδομένων εφαρμόσαμε την εξής στρατηγική:

1. **CHURN:** Επιλέχθηκε η **διαγραφή (drop)** των εγγραφών με κενή τιμή.
2. **Αριθμητικά Πεδία** ('AGE', 'TENURE_MONTHS', 'TOTAL_CHARGES'):
Επιλέχθηκε η **αντικατάσταση με τον διάμεσο** (Median Imputation).

Για τη μεταβλητή-στόχο 'CHURN', η διαγραφή είναι απαραίτητη διότι δεν μπορούμε να εκπαιδεύσουμε ή να αξιολογήσουμε αξιόπιστα ένα μοντέλο επιβλεπόμενης μάθησης με ανύπαρκτες ετικέτες, δηλαδή να βγάλουμε ορθά συμπεράσματα σύμφωνα με το προφίλ ενός

πελάτη για το αν θα φύγει ή όχι, αν δεν γνωρίζουμε την κατάσταση από προηγούμενα δεδομένα. Για τα αριθμητικά χαρακτηριστικά, επιλέχθηκε η αντικατάσταση με την διάμεσο (median) αντί του μέσου όρου, διότι ο διάμεσος είναι πιο ανθεκτικός σε ακραίες τιμές (outliers) που συχνά εμφανίζονται σε οικονομικά δεδομένα, διατηρώντας έτσι την κατανομή των δεδομένων πιο κοντά στην πραγματικότητα. Ο λόγος που δεν διαγράφουμε τις εγγραφές με κενές αυτές τις πληροφορίες, είναι γιατί η ακρίβεια τους δεν επηρεάζει τόσο το αποτέλεσμα του μοντέλου όσο η απουσία όλων των γραμμών αν τις διαγράφαμε όλες, έτσι η διάμεσος αποτελεί μια καλή στρατηγική λύση.

```
# Μετατροπή σε αριθμητικό και αφαίρεση ελλιπών τιμών στη μεταβλητή CHURN
df_cleaned = df.withColumn("TOTAL_CHARGES", col("TOTAL_CHARGES").cast("double"))

# Διαγραφή γραμμών όπου το CHURN είναι κενό
df_cleaned = df_cleaned.dropna(subset=["CHURN"])
```

Υπολογισμός και Imputation με Median

```
# Υπολογισμός Διαμέσων στις στήλες που το να λείπει η τιμή μπορεί να αντικατασταθεί από τη διάμεσο του συνόλου
numerical_cols = ['AGE', 'TENURE_MONTHS', 'MONTHLY_CHARGES', 'TOTAL_CHARGES']
median_values = {}

print("--- Υπολογισμός Διαμέσων ---")
for col_name in numerical_cols:

    median_val = df_cleaned.stat.approxQuantile(col_name, [0.5], 0.01)[0]
    median_values[col_name] = median_val
    print(f"Median for {col_name}: {median_val}")

# Αντικατάσταση των κενών με τους διαμέσους
df_clean = df_cleaned.fillna(median_values)
```

4. Βασική Περιγραφική Ανάλυση

Υλοποιήσαμε στατιστική ανάλυση στα καθαρά δεδομένα και συγκρίναμε τις μέσες τιμές ανάμεσα σε πελάτες που έμειναν (CHURN=0) και πελάτες που έφυγαν (CHURN=1).

Στατιστικά Αποτελέσματα (Aggregate by Churn):

```
churn_agg_df.show()
```

--- Βασική Περιγραφική Ανάλυση ---

Βασικά Στατιστικά (AGE, TENURE_MONTHS, MONTHLY_CHARGES, TOTAL_CHARGES):

summary	AGE	TENURE_MONTHS	MONTHLY_CHARGES	TOTAL_CHARGES
count	9700	9700	9700	9700
mean	51.413711340206184	36.54288659793814	36.53658556701044	1335.8529556701098
stddev	19.247619339313896	20.466230737374413	11.128099062861502	875.3381999556358
min	18.0	1.0	5.0	0.0
max	85.0	72.0	80.45	5197.62

Μέσος όρος TENURE_MONTHS και MONTHLY_CHARGES ανά CHURN (0: Active, 1: Churned):

CHURN	Avg_Tenure_Months	Avg_Monthly_Charges
1.0	33.546514856984174	37.013854484865405
0.0	38.312018363666176	36.254794228562346

Από την ανάλυση παρατηρούμε ότι οι πελάτες που αποχωρούν (CHURN=1) έχουν σημαντικά μικρότερο μέσο χρόνο παραμονής (Tenure) σε σχέση με τους ενεργούς πελάτες. Επίσης, φαίνεται να έχουν κατά μέσο όρο υψηλότερες μηνιαίες χρεώσεις (Monthly Charges). Το εύρημα αυτό επιβεβαιώνει την επιχειρησιακή διαίσθηση ότι οι πελάτες είναι πιο πιθανό να φύγουν νωρίς στη συνεργασία, ειδικά αν χρεώνονται με υψηλά ποσά. Αυτό θα μπορούσε να συνδυαστεί και με ένα μοντέλο τύπου Loyalty, δηλαδή πιο ευνοϊκά πακέτα σε πελάτες με μεγαλύτερη διάρκεια συμβολαίων, αν δεν χρησιμοποιείται ήδη.

5. Αρχικό Feature Engineering

Δημιουργήσαμε τρία νέα χαρακτηριστικά για να εμπλουτίσουμε την ανάλυση:

1. **NUM_SERVICES**: Το πλήθος των ενεργών υπηρεσιών (Internet, Mobile, TV).
2. **IS_LONG_TENURE**: Δυαδική ένδειξη για πελάτες με διάρκεια συμβολαίου μήνες.
3. **AVG_CHARGE_PER_MONTH**: Υπολογισμός της μέσης χρέωσης διαιρώντας τα συνολικά έξοδα με τους μήνες παραμονής (εκτός αν είναι μηδέν).

```
print("\nΔείγμα γραμμών με τα νέα πεδία (NUM_SERVICES, IS_LONG_TENURE, AVG_CHARGE_PER_MONTH):")
df_clean.select("CUSTOMER_ID", "TENURE_MONTHS", "MONTHLY_CHARGES",
                "TOTAL_CHARGES", "NUM_SERVICES", "IS_LONG_TENURE",
                "AVG_CHARGE_PER_MONTH", "CHURN").show(5)
```

--- Αρχικό Feature Engineering ---

Δείγμα γραμμών με τα νέα πεδία (NUM_SERVICES, IS_LONG_TENURE, AVG_CHARGE_PER_MONTH):

CUSTOMER_ID	TENURE_MONTHS	MONTHLY_CHARGES	TOTAL_CHARGES	NUM_SERVICES	IS_LONG_TENURE	AVG_CHARGE_PER_MONTH	CHURN
C000001	61.0	17.54	1077.63	1	1	17.666065573770492	1.0
C000002	36.0	50.82	833.94	2	1	23.165000000000003	0.0
C000003	53.0	34.44	1828.5	2	1	34.5	0.0
C000004	6.0	50.66	271.56	3	0	45.26	0.0
C000005	39.0	38.82	1519.19	3	1	38.953589743589745	0.0

only showing top 5 rows

Θέμα 2: Ανάλυση με Spark SQL & Επιβεβαίωση Επιχειρησιακών Μοτίβων

Από την **ανάλυση των δεδομένων churn** με χρήση Spark SQL προέκυψαν σημαντικά επιχειρησιακά συμπεράσματα σχετικά με την συμπεριφορά των πελατών και τους παράγοντες που επηρεάζουν την αποχώρησή τους.

Αναφορικά με τον τύπο συμβολαίου, παρατηρείται ότι οι πελάτες με το Month-to-Month συμβόλαιο εμφανίζουν ιδιαίτερα υψηλό ποσοστό churn (53.21%), σημαντικά μεγαλύτερο σε σύγκριση με τα συμβόλαια One year (20.61%) και Two year (13.65%). Το αποτέλεσμα αυτό δείχνει ότι η περιορισμένη χρονική δέσμευση συνδέεται άμεσα με αυξημένη πιθανότητα αποχώρησης.

Στη συνέχεια, η ανάλυση με βάση τον αριθμό υπηρεσιών ανέδειξε ότι οι πελάτες με μια μόνο υπηρεσία παρουσιάζουν υψηλότερο churn (47.98%), ενώ το ποσοστό μειώνεται για πελάτες με δύο υπηρεσίες (37.38%) και είναι χαμηλότερο για πελάτες με τρεις ή περισσότερες υπηρεσίες (26.84%). Το αποτέλεσμα αυτό αποδεικνύει ότι η παροχή πολλαπλών υπηρεσιών αυξάνει τη δέσμευση και μειώνει την πιθανότητα αποχώρησης.

Επιπλέον, στην **γεωγραφική ανάλυση**, διατηρήσαμε τις χώρες με τουλάχιστον 100 πελάτες και εντοπίσαμε τις σημαντικές διαφοροποιήσεις στα ποσοστά churn. Οι χώρες με τα υψηλότερα ποσοστά αποχώρησης είναι η Ιταλία (40.78%), η Γερμανία (37.03%), το Ηνωμένο Βασίλειο (36.15%) και η Ισπανία (36.10%), γεγονός που υποδεικνύει πιθανές γεωγραφικές διαφορές στη συμπεριφορά των πελατών ή στην ποιότητα των παρεχόμενων υπηρεσιών.

Συνολικά τα αποτελέσματα της ανάλυσης **επιβεβαιώνουν τα hints** του προβλήματος, καθώς διαπιστώνουμε ότι ο τύπος του συμβολαίου και ο αριθμός υπηρεσιών αποτελούν ισχυρούς παράγοντες churn, ενώ η μηνιαία χρέωση φαίνεται να λειτουργεί ως δευτερεύων παράγοντας αλλά και πάλι επιβαρυντικός για μια αποχώρηση.

1. Δημιουργία προσωρινού view(churn_view)

Στο παρόν βήμα χρησιμοποιήσαμε το καθορισμένο DataFrame που προέκυψε από το Θέμα 1, μετά την διαχείριση των ελλিপών τιμών και την δημιουργία των νέων χαρακτηριστικών. Το DataFrame αποθηκεύεται ως temporary view, ώστε να είναι διαθέσιμο για ανάλυση μέσω Spark SQL.

```
s df_clean.createOrReplaceTempView("churn_view")

print("Το καθαρό DataFrame αποθηκεύτηκε ως temporary view με όνομα 'churn_view'.")
```

Το καθαρό DataFrame αποθηκεύτηκε ως temporary view με όνομα 'churn_view'.

2. Βασικά ερωτήματα ανάλυσης churn

```
# 2.1. Churn ανά τύπο συμβολαίου
churn_by_contract = spark.sql("""
    SELECT CONTRACT_TYPE,
           COUNT(*) AS total_customers,
           SUM(CASE WHEN CHURN = 1 THEN 1 ELSE 0 END) AS churned_customers,
           ROUND(100.0 * SUM(CASE WHEN CHURN = 1 THEN 1 ELSE 0 END) / COUNT(*), 2)
           AS churn_rate_percent
    FROM churn_view
    GROUP BY CONTRACT_TYPE
    ORDER BY churn_rate_percent DESC """)

churn_by_contract.show()
```

CONTRACT_TYPE	total_customers	churned_customers	churn_rate_percent
Month-to-month	5326	2834	53.21
One year	2440	503	20.61
Two year	1934	264	13.65

```
# 2.2. Churn ανά πλήθος υπηρεσιών

churn_by_services = spark.sql("""
    SELECT
        CASE
            WHEN NUM_SERVICES = 1 THEN '1 Service'
            WHEN NUM_SERVICES = 2 THEN '2 Services'
            ELSE '3+ Services'
        END AS service_group,
        COUNT(*) AS total_customers,
        SUM(CASE WHEN CHURN = 1 THEN 1 ELSE 0 END) AS churned_customers,
```

service_group	total_customers	churned_customers	churn_rate_percent
1 Service	2149	1031	47.98
2 Services	5152	1926	37.38
3+ Services	2399	644	26.84

2.3. Churn και μηνιαία χρέωση

```
avg_monthly_by_churn = spark.sql("""
    SELECT CHURN,ROUND(AVG(MONTHLY_CHARGES), 2) AS avg_monthly_charges
    FROM churn_view
    GROUP BY CHURN
    ORDER BY CHURN
    """)
```

```
avg_monthly_by_churn.show()
```

2.3 Μέση μηνιαία χρέωση ανά CHURN και CONTRACT_TYPE

```
avg_monthly_by_churn_contract = spark.sql("""
    SELECT CONTRACT_TYPE,CHURN,ROUND(AVG(MONTHLY_CHARGES), 2)
    AS avg_monthly_charges
    FROM churn_view
    GROUP BY CONTRACT_TYPE, CHURN
    ORDER BY CONTRACT_TYPE, CHURN
    """)
```

```
avg_monthly_by_churn_contract.show()
```

CHURN	avg_monthly_charges
0.0	36.25
1.0	37.01

CONTRACT_TYPE	CHURN	avg_monthly_charges
Month-to-month	0.0	41.21
Month-to-month	1.0	38.48
One year	0.0	35.25
One year	1.0	33.44

3. Γεωγραφική ανάλυση (Top-X περιοχές)

```
churn_by_country = spark.sql("""
    SELECT COUNTRY, COUNT(*) AS total_customers,
           ROUND(100.0 * SUM(CASE WHEN CHURN = 1 THEN 1 ELSE 0 END) / COUNT(*),2)
           AS churn_rate_percent
    FROM churn_view
    GROUP BY COUNTRY
    HAVING COUNT(*) >= 100
    ORDER BY churn_rate_percent DESC
    LIMIT 5
""")
print("--Top-5 χώρες με το υψηλότερο ποσοστό churn--")
churn_by_country.show()
```

```
--Top-5 χώρες με το υψηλότερο ποσοστό churn--
+-----+-----+-----+
|COUNTRY|total_customers|churn_rate_percent|
+-----+-----+-----+
| IT    | 1003          | 40.78            |
| DE    | 1198          | 37.65            |
| GR    | 3732          | 37.03            |
| UK    | 1560          | 36.15            |
| ES    | 1050          | 36.10            |
+-----+-----+-----+
```

Θεμα 3 : Πρόβλεψη Μηνιαίας Χρέωσης με Decision Tree για δυναμική τιμολόγηση

1. Προεπεξεργασία & Pipeline

Για την προεπεξεργασία των δεδομένων εφαρμόσαμε StringIndexer στα κατηγορικά χαρακτηριστικά, ενώ στη συνέχεια χρησιμοποιήσαμε OneHotEncoder ώστε να αποφευχθεί η επιβολή τεχνητής διάταξης μεταξύ κατηγοριών. Συνδυάσαμε όλα τα αριθμητικά και κατηγορικά χαρακτηριστικά σε ένα ενιαίο διάνυσμα εισόδου με χρήση VectorAssembler. Τέλος, ορίσαμε το μοντέλο DecisionTreeRegressor και δημιουργήσαμε ένα ενιαίο Spark ML Pipeline που περιλαμβάνει όλα τα στάδια προεπεξεργασίας και εκπαίδευσης.

Επίσης, μετατρέψαμε τα κατηγορικά χαρακτηριστικά σε one-hot encoded διανύσματα με χρήση OneHotEncoder, ώστε να αποφευχθεί η επιβολή τεχνητής διάταξης μεταξύ κατηγοριών και να είναι κατάλληλα για χρήση στο μοντέλο παλινδρόμησης.

2. Εκπαίδευση και αξιολόγηση

Το μοντέλο εκπαιδεύτηκε σε σύνολο 70% των δεδομένων και αξιολογήθηκε στο υπόλοιπο 30%. Η τιμή του RMSE (7.86 €) δείχνει ότι η μέση απόκλιση της πρόβλεψης από την πραγματική μηνιαία χρέωση είναι σχετικά μικρή σε σχέση με το εύρος των λογαριασμών (περίπου 40–50 €), γεγονός που θεωρείται λογικό σε επιχειρησιακό επίπεδο. Παράλληλα, η τιμή του R^2 (περίπου 0.41) υποδηλώνει ότι το μοντέλο εξηγεί ένα σημαντικό μέρος της διακύμανσης της μηνιαίας χρέωσης, χωρίς όμως να την προβλέπει πλήρως. Συνεπώς, το μοντέλο κρίνεται κατάλληλο για ενδεικτικές προβλέψεις και απλά “what-if” σενάρια, αλλά όχι για πλήρως αυτοματοποιημένη τιμολόγηση.

Βιβλιογραφία:

<https://medium.com/@abhishiktadhar111/a-comprehensive-guide-to-data-cleaning-techniques-ebb2659c89a7>

<https://www.geeksforgeeks.org/data-analysis/data-cleansing-introduction/>

Χρήση Gemini για απορίες, επεξήγηση και διόρθωση συντακτικών λαθών των κειμένων.

Περιβάλλον Εκτέλεσης - Θεοδώρα Σταμογλου, iis22144

- Laptop - Lenovo ideapad c340 -140API (AMD -Ryzen 5, 8 RAM)

Περιβάλλον Εκτέλεσης - Γεωργιάνα Πετρίδου, ics23143

- Laptop - Macbook Pro 13 (M1)